

GPT-2 Downstream Task 프로젝트

구현 · 환경 세팅 · 실험 및 결과 분석 보고서

CS224N 스타일 GPT-2 Default Final Project | 작성일: 2026-06-03

본 보고서는 직접 구현한 GPT-2 모델을 세 가지 downstream task (감성 분류 · 패러프레이즈 탐지 · 소네트 생성)에 적용하여 학습한 과정과 결과를 정리한 것이다. 실행 환경 구축, 이식성 버그 수정, 두 가지 fine-tuning 모드(full-model / last-linear-layer) 비교 실험까지 전 과정을 포함한다.

1. 프로젝트 개요

GPT-2(124M, gpt2-small)를 처음부터 모듈 단위로 구현하고, HuggingFace 사전학습 가중치를 이식(remap)하여 세 가지 downstream task를 수행한다. 구현의 정확성은 **sanity_check.py**로 검증하였으며 "Your GPT2 implementation is correct!"를 통과하였다.

Task	데이터셋	형태	예측 방식
① 감성 분류	SST (5-class), CFIMDB (2-class)	문장 분류	마지막 토큰 → 분류 logit
② 패러프레이즈 탐지	Quora Question Pairs	문장쌍 분류	cloze 방식, "yes/no" 토큰 예측
③ 소네트 생성	Shakespeare Sonnets (154편)	언어 모델링	전체 토큰 자기회귀 생성

2. 코드 및 파일 구조

핵심 구현 파일과 역할은 다음과 같다.

파일	역할
models/gpt2.py	GPT2Model 본체. 토큰/위치 임베딩, 트랜스포머 스택, 최종 LayerNorm, 가중치 공유 LM 헤드(hidden_state_to_token), 사전학습 가중치 이식(from_pretrained).
modules/attention.py	CausalSelfAttention. causal mask + padding mask를 적용한 멀티헤드 self-attention.
modules/gpt2_layer.py	GPT2Layer. Pre-LayerNorm 구조의 트랜스포머 블록(attention→residual, FFN→residual).
optimizer.py	AdamW 옵티마이저 구현.
classifier.py	감성 분류(SST-CFIMDB). full-model / last-linear-layer 두 모드 지원.
paraphrase_detection.py	패러프레이즈 탐지(Quora). ParaphraseGPT 모델 + 학습/평가.
sonnet_generation.py	소네트 생성. top-p(nucleus) 샘플링 + temperature 기반 생성.
datasets.py	데이터 로딩 및 collate. 각 task별 Dataset 클래스.
evaluation.py	평가 함수(accuracy, F1, paraphrase/sonnet 평가).
sanity_check.py	GPT-2 구현 정확성 검증 스크립트.

3. 실행 환경 세팅

GPU가 **RTX 5070 Ti (Blackwell, compute capability sm_120)**인데, 프로젝트의 env.yml이 설치하는 기본 torch는 CUDA 11.8(cu118) 빌드로 sm_120을 지원하지 않아 GPU 커널이 동작하지 않는 문제가

있었다. 이를 해결하기 위해 **cu128 빌드의 최신 torch**로 새 conda 환경을 구성하였다.

항목	내용
conda 환경	NLP_Project (Python 3.10)
PyTorch	torch 2.11.0+cu128 (RTX 5070 Ti sm_120 GPU 연산 정상 동작 확인)
주요 의존성	transformers 4.46.3, tokenizers 0.20, einops 0.8.0, sacrebleu 2.5.1, scikit-learn, importlib-metadata
GPU	NVIDIA GeForce RTX 5070 Ti (16GB)
설치 방법	pip install torch ... --index-url https://download.pytorch.org/whl/cu128

4. 적용한 코드 수정 사항

Windows(한글 cp949 로캘) + 최신 torch 2.11 환경에서 starter 코드가 실패하여 다음 수정을 적용했다. 앞의 세 가지는 환경 이식성 문제이고, 마지막은 모델 설계 버그이다.

#	구분	수정 내용 / 사유
1	인코딩	datasets.py의 CSV open()에 encoding="utf-8" 지정. (기본 cp949로 열려 Quora UTF-8 데이터 디코딩 실패 → UnicodeDecodeError)
2	torch 직렬화	classifier.py · paraphrase_detection.py의 torch.load(..., weights_only=False). (torch 2.6+ 기본값 weights_only=True가 체크포인트의 SimpleNamespace를 언피클 불가)
3	표준출력	실행 시 PYTHONUTF8=1 설정. (소네트의 em-dash(—) print가 cp949 콘솔에서 인코딩 실패)
4	설계 버그	ParaphraseGPT 헤드를 Linear(d, 2) → gpt.hidden_state_to_token으로 변경. (데이터셋 label은 토큰 id 8505/3919인데 2-class 출력과 불일치 → CUDA assertion 크래시. 전체 vocab 위에서 예측하도록 수정)

수정 후 작은 배치 검증에서 logits 형태가 (B, 50257)로 정상 출력되고 cross_entropy/argmax가 동작함을 확인한 뒤 본 학습을 진행하였다.

5. 실험 세팅

모든 학습은 공통적으로 epoch 10, AdamW를 사용하였다. learning rate는 학습 대상에 따라 달라진다: **전체 모델을 미세조정할 때는 1e-5**(사전학습 지식 보존), **frozen GPT의 마지막 분류층만 학습할 때는 1e-3**(새 헤드를 빠르게 학습). batch size는 GPU 메모리 한계 내에서 설정하였다.

실험	fine-tune 대상	lr	epoch	batch	best dev 저장
감성: SST (full)	전체 모델	1e-5	10	64	O (dev acc)
감성: CFIMDB (full)	전체 모델	1e-5	10	8	O (dev acc)
감성: SST (last-linear)	마지막 Linear층	1e-3	10	64	O (dev acc)
감성: CFIMDB (last-linear)	마지막 Linear층	1e-3	10	8	O (dev acc)
패러프레이즈: Quora	전체 모델	1e-5	10	32	O (dev acc)
소네트 생성	전체 모델	1e-5	10	8	매 epoch 저장

Quora는 학습 데이터가 283,003개로 가장 커서, batch 8(약 4.6시간)보다 batch 32(약 2.5시간, 메모리 4.9GB)로 설정해 시간을 단축하였다. CFIMDB는 문서가 길어 batch 8로 고정된다.

6. 실험 결과 및 분석

6.1 종합 성능

Task	모드	dev accuracy	macro-F1
SST (5-class)	full-model	0.514	0.496
SST (5-class)	last-linear-layer	0.445	0.400
CFIMDB (2-class)	full-model	0.971	0.971
CFIMDB (2-class)	last-linear-layer	0.857	0.856
Quora (paraphrase)	full fine-tune	0.896	0.889

예측 파일에서 직접 재계산한 정확도가 학습 로그와 정확히 일치함을 확인하여 결과의 유효성을 검증하였다. (파란 음영 = full-model)

6.2 Fine-tuning 모드 비교 (감성 분류)

이 실험의 핵심은 "전체 미세조정 vs 마지막 층만 학습(linear probe)"의 비교이다.

Task	last-linear-layer	full-model	full의 이득
SST (5-class)	0.445	0.514	+0.069
CFIMDB (2-class)	0.857	0.971	+0.114

두 task 모두 full fine-tuning이 우수하다. 다만 CFIMDB는 쉬운 2-class 문제라 frozen GPT의 linear probe(0.857)만으로도 상당히 높은 성능을 보인다. 이는 "task 난이도에 따라 전체 미세조정의 이득 폭이 달라진다"는 점을 보여준다.

6.3 예측 분포 분석

예측 분포가 정답(gold) 분포와 유사할수록 특정 클래스로 쏠리지 않고 건강하게 학습된 것이다.

실험	예측 분포	gold 분포	비고
SST full (5-class)	0:115 / 1:320 / 2:127 / 3:338 / 4:201	0:139 / 1:289 / 2:229 / 3:279 / 4:165	gold와 형태 유사, 중립(2) 과소예측
CFIMDB full (2-class)	0:124 / 1:121	0:123 / 1:122	거의 완벽히 균형

실험	예측 분포	gold 분포	비고
Quora full	0:24866 / 1:15563	0:25537 / 1:14892	gold와 근접
CFIMDB last-linear (수정 전)	0:20 / 1:225	0:123 / 1:122	다수클래스 붕괴 (불량)
CFIMDB last-linear (재실행)	0:140 / 1:105	0:123 / 1:122	균형 회복 (정상)

당초 존재하던 last-linear-layer 예측 파일은 CFIMDB에서 거의 전부를 한 클래스로 찍는 붕괴 상태(acc 0.580)였으나, lr 1e-3로 충분히 재학습하자 균형 잡힌 분포와 acc 0.857로 정상화되었다.

6.4 학습 추이 (epoch별 dev accuracy)

epoch	0	1	2	3	4	5	6	7	8	9
SST full	.315	.443	.490	.496	.508	.500	.504	.507	.495	.514
CFIMDB full	.951	.963	.963	.971	.967	.963	.967	.967	.951	.959
Quora full	.853	.864	.872	.879	.880	.892	.889	.896	.895	.896
SST last-lin	.408	.415	.353	.433	.424	.428	.438	.445	.425	.421
CFIMDB last-lin	.739	.833	.678	.739	.657	.833	.829	.751	.857	.780

full-model은 비교적 안정적으로 수렴하는 반면, last-linear-layer(frozen GPT)는 표현력 제약으로 epoch 간 진동이 크다. best dev 시점의 체크포인트를 저장하므로 최종 모델은 진동과 무관하게 최고 성능 가중치가 보존된다.

6.5 소네트 생성

held-out 12편(id 0~11)에 대해 앞 3줄을 prompt로 받아 나머지를 생성하였다. train loss는 epoch 0의 5.047에서 epoch 9의 4.065로 꾸준히 감소했다. 생성문은 셰익스피어풍 어휘·운율을 모사하나 의미적 일관성은 제한적이며, 이는 학습 데이터가 154편으로 적고 모델이 gpt2-small인 점을 고려하면 예상되는 수준이다.

6.6 산출물 파일

종류	경로
감성 예측(full)	predictions/full-model-{sst,cfimdb}-{dev,test}-out.csv
감성 예측(last-linear)	predictions/last-linear-layer-{sst,cfimdb}-{dev,test}-out.csv
패러프레이즈 예측	predictions/para-{dev,test}-output.csv
소네트 생성	predictions/generated_sonnets.txt
체크포인트	sst-classifier.pt, cfimdb-classifier.pt, 10-1e-05-paraphrase.pt, {0..9}_10-1e-05-sonnet.pt, *-full-model.pt(백업)
학습 로그	logs/{classifier,paraphrase,sonnet,lastlinear}_*.log

7. 결론

직접 구현한 GPT-2가 sanity check를 통과하였고, cu128 환경 구축과 이식성/설계 버그 수정을 거쳐 세 downstream task를 모두 정상 학습하였다. 최종 성능은 SST 0.514, CFIMDB 0.971, Quora 0.896이며, 감성 분류에서 full fine-tuning이 last-linear-layer 대비 일관되게 우수함을 확인하였다. 특히 잘못 학습되어 있던 CFIMDB linear-probe 결과(0.580 붕괴)를 재실행으로 0.857로 정상화하여 재현 가능한 비교 실험을 완성하였다.