

감정 곡선 전체 제공 하에서의 시 생성 — Round 3 실험 보고서

Full-Trajectory Emotion Conditioning for GPT-2 Poem Continuation (EN sentiment m/v/r + KO 44/6-class)
Round 1:2 후속 상한(upper-bound) 실험 | dev #138 제외 세팅 | 작성일: 2026-06-07

초록. 앞선 두 라운드에서 전역 감정 라벨(R1)과 행 단위 감정 흐름(R2)은 시 continuation을 개선하지 못했다. 본 라운드는 남은 마지막 가능성, 즉 **정보량의 상한**을 검증한다: 시의 정답 감정 곡선 전체(미래 행 포함)를 학습과 추론 양쪽에 제공해도 생성이 좋아지지 않는가? 영어(셰익스피어 소네트)에서는 서로 다른 세 sentiment 측정 체계(m/v/r)의 14행 곡선을, 한국어(KPoEM-김소월)에서는 44종 세부감정과 6종 축약 감정의 전행(全行) 라벨열을 조건으로 부여하고, 무조건화-평균곡선-셔플곡선 통제군과 paired 비교하였다. 결과: **11개 조건화 모델 중 어느 것도 무조건화 베이스라인의 chrF/BERTScore를 의미 있게 넘지 못했고**, 정답 곡선은 셔플 곡선과 구별되지 않았으며(내용 무신호), 한국어에서는 정답 감정열을 받은 모델이 오히려 기준 모델보다 감정 흐름을 덜 따라가는 역설이 관측되었다. 재현된 유일한 효과는 train 평균 곡선의 감정 전환점(volta) 위치 개선으로, 이는 내용이 아닌 구조 prior 효과로 해석된다.

1. 배경과 연구 질문

R1(전역 라벨 1개: 예측 = 무작위), R2(prefix 행별 흐름: oracle = random)의 연속 실패 후 남은 반론은 두 가지였다. (i) 정보가 부족했다 — prefix 행의 감정만 줬으니 시 전체의 감정 전개는 몰랐다. (ii) 표현이 부적절했다 — 라벨 해상도(개수)나 측정 체계가 문제였다. Round 3는 이 둘을 정면으로 닫는 상한 실험이다: **미래 행을 포함한 전체 곡선을 (i)에, 3가지 sentiment 체계(영어)와 2가지 라벨 해상도(한국어)를 (ii)에** 대응시킨다. 정답 전체를 알려줘도 안 된다면, prompt 조건화 방식 자체의 상한이 막혀 있다는 결론이 가능하다.

주의: 미래 행 감정의 제공은 R2에서 금지했던 leakage를 **의도적으로** 허용한 것이다. 이는 배포 가능한 설정이 아니라 '정답을 다 알 때의 최대 효과'를 재는 oracle 설계이며, 본 보고서의 모든 해석은 이를 전제한다.

2. 데이터 무결성: dev #138 제외

실험 전 점검에서 영어 평가셋(dev 12편)의 소네트 #138과 채점 비공개 test셋의 '#155'가 동일한 시임을 확인했다(구두점 2자 차이, 전수 교차검사상 유일한 중복; 부수적으로 test '#156'은 실제 144번의 오번호임도 확인). dev로 모델을 선택하면 test 1편을 간접 최적화하게 되므로, **Round 3의 모든 영어 학습(dev 기반 모델 선택 포함)과 평가에서 #138을 제외했다(평가 n=11)**. 학습 데이터(소네트 1-131)에는 138이 없어 학습 자체는 영향이 없다.

3. 실험 설계

3.1 실험 구성 (학습 모델 12개 + 한국어 베이스라인 재평가 1 = 13개 setup)

언어	setup	조건 내용	존재 이유
EN	base	조건 없음 (시 본문만 학습)	기준점
EN	oracle x {m,v,r}	그 시의 정답 14행 곡선 (연속값, 3가지 측정 체계)	주 실험: 정답 곡선의 효과 상한
EN	average x {m,v,r}	train 130편 평균 곡선을 전 시에 동일 부착	시별 내용 없이 '전형적 소네트 곡선' prior만의 효과
EN	shuffled x {m,v,r}	다른 시의 정답 곡선을 순환 오배정	핵심 통제: 곡선의 형식·분포는 실제, 내용만 오류 - oracle이 이를 못 넘으면 내용 무신호
KO	base	조건 없음 (기존 무조건화 모델 재평가)	기준점
KO	fine (44종)	전행 세부감정 라벨열 (주석자 5인 다수결)	최대 해상도에서의 상한
KO	six (6종)	동일 라벨열을 6-class로 축약 (poetic 매핑)	해상도 가설(44종이 과세문?) 분리 검증

셔플 통제가 무작위 값 통제보다 강한 이유: 곡선의 값 분포·자기상관 등 통계적 성질을 전부 보존한 채 시-곡선 대응만 파괴하므로, '실제같은 곡선이 붙어 있는 효과'와 '맞는 곡선이 붙어 있는 효과'를 정확히 분리한다. 순환 오배정(i번 시가 i+1번 곡선)은 결정적이며 자기 곡선을 받는 시가 없음을 보장한다.

3.2 설계 선택의 근거

선택	내용	근거
EN 3개 측정 체계	sentiment_m(이산 -1/0/1), v(연속, VADER류), r(연속, 신경망류)	상호상관 0.28-0.61로 서로 다른 측정치 - 결과가 특정 측정기 의존인지 확인
KO test = 김소월 11편	train은 전체 368편, 평가만 김소월	R2에서 유일한 긍정 단서가 김소월 한정 oracle 우위였음 - 가장 유리한 조건에서 상한 측정. 김소월 전용 '학습'은 R2에서 데이터 축소 손실로 역효과 확인됨
KO 입력 = 30% 행	고정 '첫 3행' 대신 시 길이의 30%	한국시는 4-216행으로 길이 가변 - 비율 분할이 공정. 30%는 단시에서도 최소 1행 입력 보장(최소 1행, 최대 n-1행 클램프)
행 라벨 = 5인 다수결	주석자 5인의 라벨 인스턴스 전체 최빈값(동률은 사전순)	행당 평균 18.5개 라벨 인스턴스를 단일 라벨로 - 결정적 규칙으로 재현성 확보
조건 = 텍스트 블록	[sentiment trajectory]/[감정흐름] 자연어 블록 prefix	아키텍처 수정 없이 사전학습 어휘 지식 활용. 라벨은 숫자 ID가 아닌 단어('슬픔')로 - GPT-2가 의미를 이미 아는 토큰

4. 하이퍼파라미터 (전체 명시 + 선정 근거)

4.1 학습

항목	값	근거
random seed	11711 (전 단계 공통)	스타터 기본값. split-초기화-디코딩까지 고정해 재현성 보장. 단일 시드는 한계(8절)
optimizer / lr	AdamW(자체 구현) / 1e-5	full-model fine-tuning 표준값 - 더 크면 사전학습 지식 파괴
fine-tune 범위	전체 파라미터 (full)	조건 블록 활용법을 backbone이 학습해야 함 - head-only로는 prompt 형식 학습 불가
epochs / batch	10 / 8	전 라운드와 동일(비교 일관성). EN은 10내 단조 개선, KO는 조기 과적합을 best-dev 저장에 차단
체크포인트 선택	best dev-loss (dev도 동일 조건화)	KO 시 데이터(368편)는 1-2 epoch에 과적합 반전 - 자동 가드. dev를 조건화하지 않으면 선택 기준이 조건화 모델에 불리해짐
max_length (EN 조건화)	384	소네투 약 160토큰 + 14행 곡선 블록 약 150토큰
max_length (KO 조건화)	768	전행 라벨 블록이 행수에 비례(최장 216행) - 256이면 본문 절단. 김소월 평가 프롬프트는 실측 최대 172토큰으로 안전
학습 목표	full-text LM (조건블록+시 전체에 CE, 패딩 -100)	가장 단순한 조건화. 단, 블록 토큰에도 loss가 걸리므로 dev loss는 base와 비교 불가(6.4절)

4.2 디코딩·평가 (13개 setup 전부 동일 - 비교의 전제)

항목	값	근거
sampling	nucleus, temperature 0.8 / top_p 0.9	스타터 기본 1.2는 과발산으로 비교 노이즈 증가 - 다양성·일관성 절충점
샘플 수	시당 3회 생성, 점수 평균	평가셋이 작아(11편) 단일 표본 분산이 큼. 시드 = 기준 + 1000x샘플 + 시번호로 결정적
max_new_tokens	200	EN 11행/KO 평균 continuation 커버. 전 setup 동일 상한(긴 시는 절단 - 8절)
KO 반복 억제	no_repeat_ngram 3 / repetition_penalty 1.3	KoGPT2 반복 붕괴 방지(R2에서 확립). 모든 KO setup 동일 적용
평가셋	EN dev 11편(138 제외) / KO 김소월 test 11편	paired 비교(같은 시에 전 setup 적용)로 소표본 보완

4.3 평가 지표와 측정기

지표	정의	방향 / 비교
chrF	문자 n-gram F-score, 생성 continuation vs 정답 continuation (sacrebleu)	높을수록. 표면 유사도
BERTScore F1	contextual embedding 의미 유사도 (EN roberta-large / KO mBERT)	높을수록. 표현이 달라도 의미 포착
Volta distance	감정 곡선에서 s(i+1)-s(i) 최대 지점(전환점) 위치 차이, prefix+생성 전체 곡선 기준	낮을수록. 구조(전환 위치) 충실도
보조: traj_corr / 행감정 일치	행별 감정 궤적의 Pearson 상관 / 행 라벨 일치율(KO)	감정 흐름 추종도
측정기	EN: 사전학습 SST-2 DistilBERT(외부, leakage 없음) / KO: 자체 KOTE 분류기 + valence 매핑	생성물과 정답에 동일 측정기 적용 - 측정기 편향 상쇄

5. 결과 — 영어 (n=11, 시당 3샘플 평균)

5.1 전체 지표

setup	chrF	BERTScore	Volta(낮을수록)	traj_corr	Distinct-2
base	27.69	0.833	4.58	-0.020	0.840
orc m	25.29	0.827	4.76	0.019	0.803
avg m	24.88	0.826	3.52	0.012	0.775
shuf m	27.08	0.827	3.97	0.024	0.805
orc v	25.39	0.827	4.52	-0.146	0.797
avg v	25.86	0.828	2.94	-0.028	0.792
shuf v	26.14	0.826	5.12	0.057	0.785
orc r	26.50	0.830	4.27	0.058	0.808
avg r	26.48	0.827	4.58	-0.090	0.786
shuf r	23.87	0.824	3.70	0.108	0.767

base가 chrF(27.69)와 BERTScore(0.833) 모두에서 10개 setup 중 1위다. 정답 곡선(oracle)은 세 측정 체계 모두에서 base 아래(25.3/25.4/26.5)이고, 평균·셔플도 마찬가지다. 조건화는 또한 Distinct-2를 일관되게 낮춰(0.84에서 0.77-0.81) 반복을 늘렸다 - R2와 동일한 부작용.

5.2 paired 분석 (시별 대응 비교)

비교	chrF Δ (개선/11)	BERTScore Δ (개선/11)	Volta Δ (개선/11)
oracle m vs base	-2.40 (1/11)	-0.0058 (2/11)	+0.18 (5/11)
oracle m vs shuf m	-1.79 (2/11)	+0.0002 (7/11)	+0.79 (5/11)
oracle m vs avg m	+0.41 (7/11)	+0.0013 (6/11)	+1.24 (3/11)
oracle v vs base	-2.30 (1/11)	-0.0058 (2/11)	-0.06 (5/11)
oracle v vs shuf v	-0.76 (4/11)	+0.0016 (6/11)	-0.61 (6/11)
oracle v vs avg v	-0.47 (5/11)	-0.0011 (5/11)	+1.58 (1/11)
oracle r vs base	-1.19 (3/11)	-0.0035 (4/11)	-0.30 (6/11)
oracle r vs shuf r	+2.63 (9/11)	+0.0057 (5/11)	+0.58 (4/11)
oracle r vs avg r	+0.02 (7/11)	+0.0025 (7/11)	-0.30 (5/11)

(a) **oracle vs base**: m·v는 chrF에서 11편 중 10편 악화(각 Δ-2.40/-2.31), BERTScore도 9편 악화 - 일관된 손상. r은 가장 완만하나(Δ-1.19) 여전히 음수. (b) **oracle vs shuffled(핵심)**: m은 셔플이 우세(Δ-1.79), v는 동물권(Δ-0.76, 4/7), r만 oracle 우세(Δ+2.63, 9/11). 단 shuf_r은 전 setup 최저점(23.87)으로, 이 우세는 'oracle r이 좋다'기보다 'shuf r이 유독 나빴다'는 해석이 자연스럽고, oracle r 자체가 base를 넘지 못하므로 가설을 구제하지 못한다. 세 체계에서 방향이 제각각(셔플 우세/동물/oracle 우세)이라는 사실 자체가 내용 신호의 부재(노이즈 지배)를 시사한다. (c) **평균 곡선의 volta 효과**: avg_v 2.94, avg_m 3.52로 base(4.58) 대비 뚜렷하며, R2의 동일 관측(3.42)을 독립 재현한다. 시별 정답 곡선(oracle)은 이 효과조차 내지 못한다(4.27-4.76) - 즉 volta 개선은 '전형적 소네트 구조'라는 형식 prior의 효과이지 시별 감정 내용의 효과가 아니다.

6. 결과 — 한국어 (김소월 11편, 30% 입력)

6.1 전체 지표

setup	chrF	BERTScore	Volta(낮을수록)	traj_corr	행감정 일치
base (무조건화)	6.28	0.612	2.30	0.156	0.326
전행 44종 라벨	6.50	0.614	1.73	-0.025	0.248
전행 6종 라벨	6.42	0.618	2.27	0.041	0.287

6.2 paired 분석

비교	chrF Δ (개선/11)	BERTScore Δ (개선/11)	Volta Δ (개선/11)	traj_corr Δ	행일치 Δ
fine vs base	+0.22 (8/11)	+0.0014 (5/11)	-0.58 (6/11)	-0.182 (3/9)	-0.078 (4/11)
six vs base	+0.15 (9/11)	+0.0061 (7/11)	-0.03 (4/11)	-0.116 (2/9)	-0.038 (2/11)
six vs fine	-0.07 (7/11)	+0.0047 (8/11)	+0.55 (3/11)	+0.066 (6/9)	+0.039 (7/11)

(a) 텍스트 지표: 44종은 chrF +0.22(8/11)·BERTScore 동률, 6종은 chrF +0.15(9/11)·BERTScore +0.006(7/11) - 우세 편수는 있으나 효과 크기가 측정 노이즈 수준이다. (b) 역설: 정답 감정열을 통째로 받은 두 모델 모두 base보다 감정 흐름 추종이 나쁘다 (traj_corr: base +0.156 vs 44종 -0.025/6종 +0.041; 행일치: base 0.326 vs 0.248/0.287). 정답을 쥐여줘도 따라가지 못할 뿐 아니라 오히려 방해가 된다. (c) 해상도: 6종이 44종보다 흐름 지표에서 덜 손상되고 BERTScore가 근소 우위(+0.005, 8/11)이나, volta는 44종만 개선(1.73 vs base 2.30). 어느 해상도도 효과를 열지 못한다 - '44종 과세분' 가설 기각.

7. 논의 — 왜 정답을 줘도 안 되는가

(1) 모델은 곡선을 '읽지' 않고 '외운다'. 조건화 모델들의 dev LM loss(EN 2.43-2.83, KO 2.92-3.30)는 base(4.07/4.85+)보다 훨씬 낮지만, 이는 정형화된 곡선 블록 토큰의 예측이 쉬워서이지 시 본문을 더 잘 모델링해서가 아니다(비교 불가 수치). cross-entropy는 블록을 복제하는 법은 가르치지만 블록의 의미를 본문 생성에 연결(grounding)하도록 강제하는 항이 없다. 한국어의 역설(정답을 받고도 흐름 추종이 나빠짐)은 이 해석의 직접 증거다: 블록은 학습된 '장식'이고, 그 처리에 쓰인 용량만큼 본문 모델링이 간섭받는다.

(2) 신호 대 표본의 구조적 불리함. 조건-본문 결합을 배울 표본이 영어 130편, 한국어 368편뿐이다. 124M급 모델이 이 표본으로 '곡선의 i번째 값이 i번째 행의 정서를 지시한다'는 대응을 귀납하기는 어렵고, 셔플 통제가 oracle과 구별되지 않는 것이 그 결과다. 반면 평균 곡선의 volta 효과는 '모든 시에 같은 패턴'이라 표본 전체가 한 패턴 학습에 기여하므로 학습 가능했다고 설명된다 - 본 실험에서 유일하게 재현되는 효과가 하필 '내용 없는 prior'라는 사실은 이 표본-신호 논리와 정확히 부합한다.

(3) 측정의 한계가 가리는 부분. chrF/BERTScore는 reference 유사도이므로, 감정 흐름을 잘 따른 '다른 좋은 시'는 보상받지 못한다. 다만 이 한계만으로는 결과를 설명할 수 없다 - 감정 흐름 직접 지표(traj_corr-행일치)에서도 조건화가 이기지 못했고 한국어에선 오히려 졌기 때문이다. 즉 '지표가 못 봐서'가 아니라 '실제로 흐름 제어가 일어나지 않아서'에 가깝다.

(4) 실무적 함의. 정보량(전체 곡선)-해상도(44/6종)-측정 체계(m/v/r)-언어(영/한)를 모두 바꿔도 결론이 불변이므로, 남은 경로는 조건화 방식 자체의 변경이다: 블록 토큰 loss 마스킹(복제 학습 제거), 디코딩 시점 제어(분류기 유도 샘플링 등), 행 단위 인터리빙(라벨-행 교차 배치), 또는 더 큰 backbone. 이는 future work로 남긴다.

8. 한계

(1) 평가셋이 작다(언어당 11편, paired로 보완했으나 검정력 낮음). (2) 단일 시드 단일 실행 - 학습 분산 미측정. (3) KO 흐름 측정기는 댓글 도메인 분류기로 측정 노이즈가 있으며 valence 매핑은 6class를 3값으로 압축한다. (4) max_new_tokens 200이 긴 target을 절단한다(전 setup 동일 적용으로 비교는 공정). (5) 김소월 11편은 R2에서 유리한 단서가 나온 시인으로서의 선택이므로, 본 결과는 '가장 유리한 조건에서도 실패'로 읽는 것이 옳다. (6) 예측 planner(Method C)는 본 라운드에서도 범위 외.

9. 결론

정답 감정 곡선 전체를 학습·추론 양쪽에 제공하는 상한 설정에서도, 세 가지 sentiment 측정 체계(영어)와 두 가지 라벨 해상도(한국어) 모두에서 시 continuation 품질은 무조건화 베이스라인을 넘지 못했다. 정답 곡선은 셔플 곡선과 체계적으로 구별되지 않았고, 한국어에서는 정답 감정열이 오히려 감정 흐름 추종을 떨어뜨렸다. R1-R3을 관통하는 결론은 다음과 같다: **GPT-2 small 규모에서 텍스트 prefix 형태의 감정 조건화는 - 정보를 어떤 형식·해상도·분량으로 주든 - 시 생성을 제어하지 못한다.** 유일하게 재현되는 효과는 train 평균 곡선에 의한 감정 전환점 위치 개선뿐이며, 이는 시별 감정 내용이 아니라 장르의 구조적 전형에서 오는 prior 효과다.