

감정 정보를 활용한 GPT-2 기반 시 생성 실험

Emotion-Aware Poem Continuation with GPT-2 / KoGPT2

CS224N 스타일 GPT-2 Final Project — 확장 실험 | 작성일: 2026-06-04

본 보고서는 **감정 분류로 학습된 정보가 시 생성에 도움이 되는가**를 검증한 실험을 정리한다. 영어(GPT-2)와 한국어(KoGPT2) 두 언어에서, (A) 예측된 감정 라벨을 prompt에 붙이는 방식과 (B) 감정 분류로 먼저 fine-tuning한 backbone을 시 생성으로 이어받는 방식을 baseline과 비교하였다. 데이터 전처리·모델 학습·생성 평가의 전 과정과 최종 결과(CHRF)를 포함한다.

1. 연구 질문 및 동기

시 생성은 문법뿐 아니라 앞부분의 정서·분위기를 이어받아야 하는 어려운 생성 과제이다. GPT-2가 인간처럼 감정을 이해하지는 못하지만, 감정 분류 task를 통해 감정 관련 표현 패턴을 학습할 수 있다. 이 표현이 시 생성으로 전이되는지를 다음 질문으로 검증한다.

#	연구 질문
주질문	감정 supervision은 GPT-2 계열 모델의 시 continuation 성능(CHRF)을 향상시키는가?
Q1	예측된 감정 라벨을 prompt prefix로 넣으면 성능이 향상되는가? (Pipeline A)
Q2	감정 분류 fine-tuning 후 시 생성 fine-tuning을 하면 향상되는가? (Pipeline B)
Q3	이 효과가 영어 GPT-2와 한국어 KoGPT2에서 비슷하게 나타나는가?
Q4	영어/한국어 감정·시 데이터는 분포·길이·tokenization에서 어떤 차이를 보이는가?

2. 데이터셋 및 전처리

감정 분류용 데이터(대규모)와 시 생성용 데이터(소규모)의 두 축으로 구성된다. 외부 데이터는 repo에 커밋하지 않고 전처리 스크립트로 재생성한다.

용도	데이터셋	언어	규모(train)	형태
감정 분류	dair-ai/emotion	영어	16,000	6-class single-label
감정 분류	KOTE → 6-class 변환	한국어	11,880	43-class multi → 6-class single
시 생성	Shakespeare Sonnets	영어	131편	첫 3행 → 나머지
시 생성	KPoEM (근대시)	한국어	368편	첫 3행 → 나머지

감정 6-class 공통 라벨: sadness, joy, love, anger, fear, surprise. KOTE는 rater 다수결(≥ 3) 기반 strict single-label subset으로 변환하였다. 시 데이터는 poem 단위 80/10/10 split(고정 seed).

2.1 감정 라벨 분포 (train)

두 언어의 분포가 크게 다르다(Q4). 영어는 joy, 한국어는 anger가 지배적이며, 이 불균형 때문에 분류 학습 시 class weight 보정이 필요했다.

언어	sadness	joy	love	anger	fear	surprise	불균형(최대/최소)
EN	4666	5362	1304	2159	1937	572	9.4x

언어	sadness	joy	love	anger	fear	surprise	불균형(최대/최소)
KO	433	3194	1038	5773	329	1113	17.5x

3. 모델 및 실행 환경

영어/한국어는 코드 경로를 분리하였다(한국어 원본 세팅을 그대로 보존하기 위함). 두 모델 모두 GPT-2 small 규모(hidden 768, 12 layers, 12 heads)로 비교 가능성을 맞췄다.

언어	모델	tokenizer	비고
영어	직접 구현한 GPT2Model (gpt2 가중치 이식)	gpt2 BPE (vocab 50,257)	분류 head / tied LM head
한국어	skt/kogpt2-base-v2 (HuggingFace 원본)	SentencePiece (vocab 51,200)	AutoModelForCausalLM

실행 환경: conda **NLP_Project**, torch 2.11.0+cu128 (RTX 5070 Ti, 17GB), transformers 4.46.3, sacrebleu 2.5.1(정식 CHRF). KoGPT2 tokenizer는 special token을 명시적으로 지정해 로드해야 (pad=<pad>, eos=</s>) 임베딩 범위 초과 오류를 피한다.

4. 실험 설계

baseline(감정 미사용) 대비 두 가지 감정 주입 방식을 비교한다. 모든 setup은 동일한 학습 설정(epoch 10, batch 8, lr 1e-5, best dev-loss 저장)과 동일한 디코딩을 사용하여, 성능 차이가 오직 감정 정보에서 비롯되도록 통제하였다.

ID	언어	설정	목적
E0 / K0	영/한	시 SFT만 (baseline)	감정 미사용 기준선
E1 / K1	영/한	예측 감정 prefix + 시 SFT	명시적 감정 conditioning (Pipeline A)
E2 / K2	영/한	랜덤 감정 prefix + 시 SFT	prefix 통제군 (감정 내용 효과 분리)
E3 / K3	영/한	감정 분류 SFT → 시 SFT	표현 전이 (Pipeline B)

E2/K2(랜덤 prefix)는 핵심 통제군이다. E1이 E0보다 좋아져도 그것이 '감정 정보' 때문인지 단순히 'prefix 토큰 추가' 때문인지 구분하려면 E1 vs E2 비교가 필요하다.

평가: 시의 첫 3행을 입력해 나머지를 생성하고 reference와 **CHRF**(character n-gram F-score)로 비교한다. 주지표는 continuation CHRF(생성된 뒷부분 vs 정답 뒷부분), 영어는 full-poem CHRF도 보고. 디코딩은 nucleus sampling(temp 0.8, top_p 0.9), prompt당 3회 생성 후 CHRF 평균(소규모 평가셋의 분산 완화). 한국어는 반복 붕괴 방지를 위해 no_repeat_ngram=3, repetition_penalty=1.3을 모든 K setup에 동일 적용. 평가셋은 영어 12편, 한국어 47편.

5. 실험 과정 (파이프라인)

단계	내용	결과/비고
Phase 0	외부 데이터 다운로드·전처리, glue layer 검증	CHRF identity 100.0 확인
Phase 1	6-class 감정 분류기 SFT (영/한)	분류기 산출 (Pipeline A/B 전제)
Phase 2	시 생성 baseline SFT (E0/K0)	EN 정상 수렴, KO epoch1 과적합
Phase 3	생성+CHRF 평가 인프라 구축	한국어 반복붕괴 발견·해결
Phase 4	감정 prefix 실험 (E1/E2, K1/K2)	Pipeline A
Phase 5	sequential SFT 실험 (E3/K3)	Pipeline B
Phase 6	종합 분석 및 보고서	본 문서

Phase 3에서 KoGPT2가 plain sampling 시 같은 구절을 무한 반복("백골만 따라갔다"×N)하여 CHRF가 바닥(~3)으로 떨어지는 문제를 발견하고, 반복 억제 디코딩으로 자연스러운 생성(CHRF ~9)을 회복하였다. 한국어 시 데이터(368편)는 epoch 1 이후 dev loss가 상승하여, best dev-loss 체크포인트 저장으로 과적합을 자동 차단하였다.

6. 실험 결과

6.1 감정 분류기 성능 (Phase 1)


언어	dev accuracy	macro-F1	sadness	joy	love	anger	fear	surprise
EN	0.917	0.899	0.94	0.94	0.87	0.91	0.86	0.87
KO	0.820	0.704	0.67	0.84	0.63	0.91	0.60	0.58

영어가 한국어보다 높다(macro-F1 0.899 vs 0.704). 한국어 fear-surprise는 표본이 적어 약하지만, class weight 보정 덕분에 anger(48.6%)로의 다수클래스 붕괴는 발생하지 않아 다양한 라벨을 예측한다 — 이는 Pipeline A 실험이 성립하기 위한 전제이다.


6.2 시 생성 CHRF 결과 (전체 매트릭스)

setup	continuation CHRF	full-poem CHRF	baseline 대비
E0	27.81	42.30	— (기준)
E1	26.57	41.18	-1.24
E2	26.41	40.97	-1.40
E3	23.67	39.27	-4.14
K0	7.16	25.27	— (기준)
K1	7.17	25.07	+0.02
K2	7.27	25.58	+0.11
K3	7.26	25.46	+0.10

영어 (E0~E3) continuation CHRF



한국어 (K0~K3) continuation CHRF



6.3 핵심 비교 (paired, 시별 대응 비교)

비교	평균 Δ	향상/악화 (편수)	해석
E1 vs E0	-1.24	5 / 7 (12편)	예측 감정이 prefix가 baseline을 이기는가?
E1 vs E2	+0.17	6 / 6 (12편)	예측 감정이 랜덤 prefix보다 나은가? (A의 핵심)
E3 vs E0	-4.14	1 / 11 (12편)	sequential SFT가 baseline을 이기는가?

E1 vs E2가 +0.17(6:6 무승부)인 점이 결정적이다 — 올바르게 예측한 감정 라벨이 랜덤 라벨보다 나은 게 없으므로, 감정 내용 자체는 CHRF에 신호를 주지 못했다. E3는 11/12편에서 악화(평균 -4.14)되어 표현 전이가 오히려 시적 능력을 훼손했음을 보여준다.

6.4 추가 분석 — 길이 및 tokenization (Q4)

언어/tokenizer	글자수/편	토큰수/편	글자/토큰
영어 / gpt2	610	160	3.8
한국어 / kogpt2	318	168	1.9

한국어 시는 글자수가 영어의 약 절반이지만 토큰수는 비슷하다 — 한국어 tokenization이 더 조밀하여 (글자당 토큰이 많아) 같은 편수라도 학습 신호의 성격이 다르다. 동일 epoch 비교가 불공정해질 수 있어 best dev-loss 기준 선택으로 통제하였다.

7. 결론 및 한계

감정 supervision은 두 방법·두 언어 모두에서 시 continuation CHRF를 향상시키지 못했다. Pipeline A에서는 예측 감정이 랜덤 prefix와 차이가 없었고(E1과 E2가 거의 동일), Pipeline B(sequential SFT)는 영어에서 오히려 성능을 일관되게 떨어뜨렸으며(11/12편 악화) 한국어는 변화가 없었다. 이는 proposal의 Expected Outcome #3에 해당하는, 그 자체로 의미 있는 부정적 결과이다.

원인으로는 (1) 감정 데이터(트윗·댓글)와 시(소네트·근대시)의 큰 도메인 불일치, (2) 시 데이터의 절대량 부족(131/368편), (3) CHRF가 reference 표면 유사도만 측정하여 정서적·시적 품질을 반영하지 못하는 점을 들 수 있다. 특히 (3) 때문에 감정적으로 잘 이어진 시도 reference와 다르면 낮은 CHRF를 받을 수 있다.

향후 과제: 시 도메인에 더 가까운 감정 데이터, human preference 또는 LLM-as-a-judge 평가, 생성 시의 emotion consistency·다양성(Distinct-n) 측정을 통해 CHRF의 한계를 보완할 수 있다.