

감정 흐름(Trajectory) 기반 시 생성 — 후속 진단 실험 보고서

Line-level Emotion / Sentiment Trajectory Guidance for GPT-2 Poem Continuation

1차 실험 후속 | KPoEM line trajectory + Shakespeare Volta Sentiment | 작성일: 2026-06-06

1차 실험에서 global emotion prefix와 sequential SFT는 시 continuation을 개선하지 못했다. 본 후속 실험은 실패 원인을 분해한다: **감정 라벨이 너무 거칠어서(coarse) 실패했는가? 행 단위로 구조화된 감정 흐름을 주면 달라지는가?** 이를 위해 (1) KPoEM line-level 감정 trajectory(한국어), (2) Shakespeare 14행 sentiment trajectory(영어), (3) prefix 비율 30/50/70%, (4) 김소월 시인 특화의 네 축으로 oracle / average / random 통제 비교를 수행하고, CHRF 외에 BERTScore와 감정 궤적 지표(MSE-Correlation-Volta)로 평가하였다.

1. 실험 설계

축	조건	통제 논리
KO 첫3행	baseline / oracle / average / random trajectory	oracle이 random보다 좋아야 '감정 내용' 신호
KO ratio	30% / 50% / 70% prefix x 위 4조건	문맥(감정 흐름)을 많이 줄수록 효과가 커지는가
EN sonnet	baseline / Method A(oracle 14행 곡선) / Method B(train 평균 곡선)	정답 감정 곡선의 upper-bound 효과
김소월	Sowol 전용 학습(131편) + 전체모델의 Sowol-test 교차평가	감정 전개가 정형화된 시인에서의 효과

공통: 학습은 trajectory prompt + 시 전체의 LM fine-tuning(conditioned_full_text), 평가는 model_input prompt로 생성 후 reference 비교. 미래 행의 감정은 입력에 쓰지 않으며(leakage-safe), 평균 곡선은 train에서만 계산. 모든 setup 동일 디코딩(temp 0.8, top_p 0.9, 시당 3샘플 평균; KO는 반복억제 동일 적용). epoch 10, batch 8, best dev-loss 저장. 평가셋: KO 47편, EN 12편, Sowol 11편.

2. 평가 지표 (full tier)

지표	측정 대상	방향
CHRF	표면(문자 n-gram) 유사도	높을수록
BERTScore F1	의미 유사도 (contextual embedding)	높을수록
Trajectory MSE / Corr	행별 감정(valence) 궤적의 거리 / 모양 일치	MSE 낮을수록 / Corr 높을수록
Volta distance	감정 전환점 위치 차이 (prefix+생성 전체 곡선)	낮을수록
행감정 일치(KO)	행별 6-class 감정 라벨 일치율	높을수록
Distinct-2	반복 없는 다양성	높을수록

측정기: EN = 사전학습 SST-2 DistilBERT(외부 모델, leakage 없음) 행별 score, KO = 1차에서 학습한 KOTE 감정 분류기 행별 적용 + valence 매핑(joy/love=+1, surprise=0, sadness/anger/fear=-1). 생성물과 reference에 같은 측정기를 적용해 측정기 편향을 상쇄.

3. 결과

3.1 한국어 — 첫 3행 trajectory (HANDOFF 최우선 실험)

setup	CHRF	BERTScore	TrajMSE	TrajCorr	Volta	행감정일치
K base	7.16	0.622	1.518	0.022	1.94	0.325
K orc	7.13	0.625	1.429	0.060	1.61	0.314
K avg	7.09	0.624	1.394	0.023	1.79	0.313
K rnd	7.08	0.623	1.401	0.088	1.88	0.328

CHRF-BERTScore는 전부 flat. traj_corr은 oracle(+0.038 vs base)이 올라 보이지만 **random(0.088)이 oracle(0.060)보다 높다** — oracle vs random 차이는 +0.007(17/32)로 무의미. 행 단위로 구조화해도 감정 '내용'은 신호를 만들지 못했다.

3.2 한국어 — prefix ratio 30/50/70%

ratio 30%

setup	CHRF	BERTScore	TrajMSE	TrajCorr	Volta	행감정일치
K r30 base	7.57	0.627	1.487	0.039	1.53	0.316
K r30 orc	7.46	0.625	1.389	0.017	1.77	0.319
K r30 avg	7.59	0.629	1.579	-0.008	1.72	0.274
K r30 rnd	7.76	0.629	1.544	-0.030	1.73	0.286

ratio 50%

setup	CHRF	BERTScore	TrajMSE	TrajCorr	Volta	행감정일치
K r50 base	7.05	0.623	1.457	0.031	0.99	0.291
K r50 orc	7.17	0.625	1.466	0.057	1.06	0.285
K r50 avg	7.29	0.625	1.371	0.136	1.35	0.317
K r50 rnd	7.28	0.623	1.513	0.040	1.28	0.287

ratio 70%

setup	CHRF	BERTScore	TrajMSE	TrajCorr	Volta	행감정일치
K r70 base	5.60	0.606	1.511	0.014	1.38	0.308
K r70 orc	5.91	0.612	1.481	0.110	1.44	0.308
K r70 avg	5.87	0.612	1.419	0.071	1.59	0.309
K r70 rnd	5.82	0.612	1.520	0.156	1.13	0.254

어떤 ratio에서도 oracle이 random을 일관되게 이기지 못한다 (r70: oracle corr 0.110 vs random 0.156). 문맥을 더 줘도 결론은 같다. r70의 CHRF 하락(약 5.8)은 짧아진 target과 생성 길이 상한의 영향으로 모든 조건에 동일하게 작용한다.

3.3 영어 — sentiment trajectory (Method A/B)

setup	CHRF	BERTScore	TrajMSE	TrajCorr	Volta	행감정일치
E base	27.81	0.833	1.677	0.017	4.50	--
E orc	24.96	0.823	1.931	-0.062	4.75	--
E avg	24.75	0.826	1.781	0.017	3.42	--

Oracle 곡선이 오히려 일관되게 해를 끼쳤다: paired에서 CHRF 악화 12/12 (Δ -2.84), BERTScore 악화 12/12. traj_corr도 개선 없음. 유일한 예외는 Method B(average)의 Volta distance 개선(3.42 vs base 4.50) — 평균 곡선이 sonnet의 구조적 전환 위치에 약한 prior로 작동했을 가능성. 또한 conditioning이 영어 생성의 Distinct-2를 낮춰(0.85 -> 0.74) 반복을 늘렸다.

3.4 김소월 — 유일한 긍정적 단서

전체-KPoEM 모델 (Sowol test 11편 한정)	TrajCorr	TrajMSE	행감정일치	BERTScore
baseline	-0.173	1.804	0.289	0.604

전체-KPoEM 모델 (Sowol test 11편 한정)	TrajCorr	TrajMSE	행감정일치	BERTScore
random traj	0.127	1.586	0.294	0.608
average traj	0.010	1.553	0.311	0.608
oracle traj	0.199	1.356	0.357	0.612

김소월 시 11편으로 한정하면 **oracle이 모든 통제군을 이긴다**: traj_corr 0.199 (random 0.127, average 0.010, baseline -0.173), 행감정 일치 0.357 최고, TrajMSE 1.356 최저. 다만 random도 크게 오르므로 상당 부분은 prefix 형식 효과이고, n=11이라 시사적 수준이다. 감정 전개가 정형화된(그리움-상실-체념) 시인에서는 감정 가이드가 약한 신호를 가질 수 있다는 유일한 단서. 한편 Sowol 전용 학습(S_base/S_orc, 131편)은 전체-KPoEM 학습보다 못했고 내부 비교도 무신호 — 데이터 축소 손실이 특화 이득을 압도한다.

4. 결론

1) Global prefix(1차)에 이어 **행 단위로 구조화된 line-level 감정 trajectory도 시 continuation을 개선하지 못했다** — 모든 지표에서 oracle과 random의 차이가 없다(감정 '내용' 무신호). 2) prefix 비율을 30-70%로 바꿔 문맥을 늘려도 결론은 변하지 않는다. 3) 영어에서는 정답 sentiment 곡선조차 표면·의미 지표를 일관되게 악화시켰다(12/12). 4) baseline들의 traj_corr이 0 근처라는 사실 자체가 중요하다: GPT-2 small은 애초에 reference의 감정 흐름을 따라가지 못하며, prompt 조건화로는 이를 바꾸지 못했다. 5) 결론: **감정 분류 능력은 곧바로 생성 제어 능력으로 이어지지 않는다**. 김소월 한정 oracle 우위(3.4)가 유일한 향후 과제 단서다.

한계: KO trajectory 측정기는 댓글 도메인 분류기라 측정 노이즈가 있고, valence 매핑은 6-class를 3값으로 압축한다. 평가셋이 작아(12-47편) 개별 비교의 검정력이 낮으며, 생성 길이 상한이 긴 target(r70)의 CHRF를 구조적으로 낮춘다. Method C(predicted planner)는 scope 외로 남겼다.